

AI演义

36篇论文开启你的探索之旅

美团光年之外产品负责人 | 谢青池

即刻/小红书 @skyxqc

我当时为什么读论文

- 想通过理解基本原理，来了解这个新的世界的边界
- AI领域高速变化，想掌握一些3-5年不变的知识
- 作者写论文的目的：研究如何解决一个问题

碰到了什么挑战，做了何种准备

- 提前把线性代数、概率论与随机过程、偏微分方程等数学基础重新用国外的材料学了一遍，收获颇丰
- 论文是英文的，有语言门槛；即使是熟悉的单词，也有专业含义
- 阅读了一些介绍性的书籍和材料，对深度学习的基础框架/概念/历史建立了初步的理解

如何用AI学习AI，应对这些挑战

- 沉浸式翻译：用AI解决英文阅读问题，还可以翻译YouTube
- AI是身边最好的老师。需要熟悉它，并学会提问
- 充分利用好Artifact等可视化工具。随时问Dia的效率也很高

体系化的学习路书： 视频+书籍

视频教程：

吴恩达的机器学习/AI课程

李宏毅： 生成式AI时代下的机器学习(2025)

Andrej Karpathy的YouTube

B站： 李沐论文精读系列

B站： 3Blue1Brown的数学与神经网络介绍部分

B站： 王木头学科学

B站： Zomi

书籍：

《一站式LLM底层技术原理入门指南》

《动手学深度学习（PyTorch版）》：

作者李沐本人有配套中文视频

《深度学习的数学》

小建议：

英文源的内容质量远大于中文，80%的时间应该花在英文内容上。

整个分享的结构

1. 历史的视角，编年体和纪传体并举：讲述论文的历史背景，当时碰到了什么样的变化/挑战，作者是如何解决问题的，对后世产生了怎样的影响
2. 范式变迁的视角：我们并非从零开始发现世界，而是在原有范式的框架内前行。原有的范式，危机以及革命都是什么？支线如何走到舞台的中心？

*某篇文章驱动了范式变迁，或者是某个范式里的代表性工作
3. 人的视角：这些作者如何登上舞台，又在后世扮演了什么角色


深度神经网络随着这四个要素的发展而发展

| 芯片（算力的载体） | infra（操作芯片软件系统）

| 数据 | 模型结构

我们将从4个方面，分别按时间顺序来展开：

模型的范式变迁




Infra与数据变迁




语言模型的发展



多模态模型的发展




模型的范式变迁



故事要从1999年的 第一颗GPU开始讲起

1999年 GeForce 256上市

能够独立处理三维图形中的几何计算
从CPU中脱离



2001年 GeForce 3上市

入了可编程的顶点着色器和像素着色器
允许开发者编写着色器 (shader)
控制图形渲染过程
人们开始研究如何通过GPU编程, 利用
其并行计算的能力

Brook: 用GPU进行计算 (2004.08)

➡ *Brook for GPUs: Stream Computing on Graphics Hardware*

历史背景

若以FLOPS为衡量单位，GPU因高度并行的处理架构，其计算能力在快速超越CPU，并拉大差距。同时，许多科学计算、数据处理任务（包括早期的神经网络探索）本质上是数据并行的，这与GPU在图形渲染时处理成千上万像素或顶点的方式非常相似。

我们能不能利用这种计算能力，将这些计算任务映射到GPU的并行单元上呢？能，但还是太难用了。虽然着色器提供了编程语言，但缺乏高级语言的便利性（如复杂数据结构、标准的库函数支持）和抽象能力；代码高度依赖特定的硬件，可移植性差。

核心贡献


将底层图形硬件的复杂细节进行抽象化和虚拟化（将GPU抽象为流式处理器），开发者可以用更高级的Brook语言（C语言的扩展）来进行编程，获得跨平台能力，同时与手写的GPU代码性能相当。

引入了数据并行的基本框架：流(Streams)、核函数 (Kernels)和规约 (Reductions)等，设计了一个编译器和运行时系统。

作者

Ian Buck：之后加入NVIDIA，成为 CUDA的创始成员，至今仍是NVIDIA负责CUDA的VP。

Pat Hanrahan：凭借在计算机图形学（包括GPU架构和编程）方面的卓越贡献，与Ed Catmull共同获得了**2019年的图灵奖**。他也是也是Pixar动画工作室的创始员工之一，三次获得奥斯卡金像奖。同时还是Tableau的联合创始人和首席科学家，2019年被Salesforce以约157亿美元的价格收购。横跨产学研三界，非常典型的硅谷创新精英。



AlexNet: 深度学习的开端（2012.10）

历史背景

李飞飞团队创建并维护的ImageNet数据集，提供了一个前所未有的、大规模、标注良好的图像数据库（14,197,122张标注图像，21,841个类别，按照WordNet的语义层次结构组织）和年度竞赛平台（ILSVRC），为评估和比较各种视觉识别算法提供了一个标准的、极具挑战性的基准。2010年的第一届，NEC Labs America获得冠军，地平线的余凯是作者之一（传统方法，特征提取）。

机器学习领域，范式仍然被手工特征提取的传统方法所主导，人们都在这个范式下思考问题（Yann LeCun的论文被拒，因为神经网络），普遍认为视觉系统需要通过对任务本质的详细理解来精心手工设计。仅通过向神经网络展示自然图像中的对象示例及其对应名称，让网络从训练数据中获取全部知识，这一方法永远无法解决图像分类任务。

作者说，我们知道出了什么问题：要使深度神经网络发挥作用，它们需要更多的标记数据和更多的计算量。

核心贡献

支线范式取得突破性进展，开启了深度学习的时代，间接催生了Google Brain

训了迄今为止最大的卷积神经网络，6250万个参数和65万个神经元，取得了迄今为止最好的结果。

用了ImageNet数据集和GPU，充分的scale了数据和算力。用了一些小技巧：数据增强/Dropout

➡ *ImageNet Classification with Deep Convolutional Neural Networks*

作者

Alex Krizhevsky：infra达人，负责搞定GPU（有CUDA了但比较难用）。

Ilya Sutskever：OpenAI的联合创始人及首席科学家。

Geoffrey E. Hinton：诺贝尔奖获得者，深度学习领域的先驱和泰斗，被称为“深度学习教父”之一（与Yann LeCun、Yoshua Bengio并称，三人共同获得2018年图灵奖）。他在反向传播算法、受限玻尔兹曼机（RBMs）、深度信念网络（DBNs）等方面有开创性贡献。AlexNet的成功极大地验证了他长期坚持的深度学习路线的潜力。

对序列建模：seq2seq和Attention的引入（2014.09）

历史背景

当时的主流范式是传统机器翻译方法（基于统计，SMT），需要复杂的特征工程和组合多个子系统，有大量人工操作

深度神经网络（DNN）由于结构问题，只能输出固定长度向量，无法解决翻译等序列到序列的问题（翻译/语音识别/问答）

早期的Encoder-Decoder结构中，源序列被编码为固定长度的向量（隐藏状态），产生了瓶颈。随着输入序列的长度增加，性能急剧下降（隐藏状态不够大了）

核心贡献

证明了领域无关，仅仅学习将序列映射到序列的通用方法，能够超越 SMT 系统（且在相对未经优化时就具备这个能力）；支线范式取得突破性进展

复兴了Encoder-Decoder结构，借助LSTM，解决了序列到序列的建模问题

引入了注意力机制，解决了隐藏状态的性能瓶颈，为Transformer的诞生埋下了伏笔：通过将输入句子编码为一系列向量，为输入的每个词生成一个表示（annotation）；并在解码时计算每个源词表示对生成当前目标词的注意力权重（attention weights），这些权重被用来计算一个加权的源表示上下文向量（context vector），与先前生成的目标词以及解码器的隐藏状态一起，用于预测下一个目标词。

作者

seq2seq：Ilya Sutskever：2024，该论文被评为“Test of Time”，Ilya对这篇论文十周年的回顾：预训练时代的终结；Oriol Vinyals：Gemini 预训练的负责人；Quoc V. Le：Gemini 后训练的负责人

Attention：Dzmitry Bahdanau，这种注意力机制后来被称为Bahdanau Attention；指导老师Yoshua Bengio：2018年图灵得主，与Geoffrey Hinton和Yann LeCun共享

蒸馏：模型能被学习吗？（2015.03）

➡ *Distilling the Knowledge in a Neural Network*

历史背景

深度学习取得突破，在CV/翻译/视频等领域都有产出，确立了新的范式；在这个范式中，模型越来越大，带来了新的问题（需要发展辅助技术）

模变大型的问题：计算成本高，部署困难，推理延迟高

核心贡献

找到一种新的方法，将知识从繁琐的模型转移到一个更适合部署的小模型：

用教师模型在较高温度产生的“软标签”（softmax层输出的类概率分布）和“硬标签”（正解）去拟合学生模型，让学生模型学会泛化

开创了知识蒸馏这项技术，建立了教师-学生学习范式

作者

Geoffrey Hinton、Oriol Vinyals和Jeff Dean。

Jeff Dean是Google fellow，美国国家工程院院士，Google Brain的创始人之一，设计了MapReduce分布式计算框架，领导开发了开源机器学习框架TensorFlow，是现代分布式系统和机器学习领域的顶尖专家之一。

ResNet: 比深更深 (2015.12)

➡ *Deep Residual Learning for Image Recognition*

历史背景

在模型scale的过程中，人们一方面通过蒸馏等方法把模型做小以避免其劣势，也在探索把模型继续scale去获得更多的收益

但和设想的不同，模型随着层数的增加，非但没有持续提升，反而出现了性能的下降，这就是模型的退化问题。

核心贡献


引入了残差学习：将层次的学习目标改为学习残差函数，其参考层次输入，而不是学习无参考函数。

ResNet有效地缓解了梯度消失/爆炸问题，并解决了困扰研究者们“退化”问题，使得训练非常深（百层乃至千层级别）的神经网络成为可能。在此之前，网络的深度通常限制在几十层以内

直至今今天，我们所熟悉的那些网络（Transformer等），仍然是残差网络

作者

何恺明（MIT教授）、张祥雨（阶跃星辰cofounder/首席科学家）、任少卿（蔚来自动驾驶负责人）和孙剑（去世前为旷视科技首席科学家）



Transformer来了！ 拉开一个时代的序幕（2017.06）

➡ *Attention Is All You Need*

历史背景

在序列建模领域，RNN+Encoder-Decoder结构+注意力机制，已经占据主导地位

RNN的问题在于不好做并行计算（没中硬件彩票），CNN虽然容易并行（想想AlexNet），但难以捕捉长距离依赖

核心贡献

在上个范式的要素中，敏锐的抓住了最核心的要素：注意力机制，完全基于此来对序列关系进行建模（后续发展中，Encoder这个要素也被丢掉了），理论上提高了捕捉规律的能力：

（1）模型“关联来自两个任意输入或输出位置的信号所需的操作数量被减少到固定数量”，从而更容易学习远距离位置之间的关系，提高了对序列规律的建模能力（token能对上下文窗口内的任意其他token建模，某种意义上说，就是给了token上下文）

（2）自注意力：将原始embedding线性映射（论文中是降维）到Q，和K计算相关关系（用点积），得到的值按 $\sqrt{d_k}$ 缩放，softmax得到注意力权重。将其和V加权求和，得到上下文向量；多头拼接后回到原始embedding维度

Transformer特别适合并行计算，抽中了硬件彩票。但需要做绝对位置编码和mask

建模能力增强+适合并行，为后面“大力出奇迹”的scaling埋下了伏笔

作者

Aidan N. Gomez, Niki Parmar, Llion Jones 共同创立了 Cohere（Jones后来离开创立 Sakana AI），Noam Shazeer 联合创立了 Character.AI，Illia Polosukhin 联合创立了 Near Protocol 区块链平台，Jakob Uszkoreit 联合创立了 Inceptive

Noam：We offer no explanation as to why these architectures seem to work; we attribute their success, as all else, to divine benevolence

AlphaGo Zero: 强化学习的突破（2017.10）

➡ *Mastering the Game of Go without Human Knowledge*

历史背景

AlphaGo击败了李世石但仍然有其局限性（依赖人）：

1. 需要从人类专家棋谱中学习，模仿人类的下法；
2. 神经网络的输入，除了棋子位置，还包括了人类设计的特征（如“气”、“眼”等围棋概念）。

对人的依赖带来两个问题：

1. 模仿人类，意味着AI上限在某种程度上被人类的理解水平所束缚，带来认知瓶颈；
2. 还有很多问题是新问题，不像围棋那样存在现成的数据，依赖人就无法探索未知的边界

核心贡献

纯粹只用强化学习来进行训练，不但在效果上取得了突破，同时训练效率大幅提升：比AlphaGo Lee用了更少的卡，在36小时后就取得超越

启发了OpenAI开发thinking模式（test-time compute scaling）：AlphaGo Zero每走一步棋都会执行1600次MCTS搜索。事实上，不做thinking的话，至今没有哪个围棋模型能击败人类

作者

Karen Simonyan：后来成为Inflection co-founder，被并购至Microsoft AI

现代MoE的开端（2017.01）

Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer

历史背景

人们意识到，更大参数的模型能从更大规模的数据集中提取出更多规律，随着无监督学习的流行，大规模的数据集已经就位

模型参数的变大，会显著的增加训练成本，但这是一次性投入（可以被摊销），但每次推理的成本（边际成本）也会因此显著上升

人类的大脑是分区的，每次思考并不会激活全部区域，所以大脑是“稀疏”和“专业化”的：如果能训练一个有海量参数（知识库）的神经网络，但在处理每个具体任务时，只动用其中一小部分相关的计算资源，成本就能降低

核心贡献

解决了过往范式的问题（训练中的关键技术挑战），驱动范式回归。简言之就是把MoE在深度学习领域搞work了（MoE的概念在1990年代由Hinton等人提出）

MoE这个范式，解决了AI在实际使用中的成本（推理费用）问题，是应用大规模普及的卡点

“获得了超过 1000 倍的模型容量提升，同时仅在计算效率上略有损失”，换言之，就是成本基本为原先的千分之一

作者

Noam Shazeer：Transformer的核心作者

Geoffrey Hinton：90年代提出MoE

CoT: Prompt Engineering的奠基之作（2022.01）

Chain-of-Thought Prompting Elicits Reasoning in Large Language Models

历史背景

人们发现，增强LLM的规模虽然会带来广泛的好处，但在算数/常识/符号推理等领域收益不足

SFT虽然能够解决推理的问题，但构建大规模的推理监督数据成本高昂；传统的few-shot方法，在推理能力的任务上效果不佳

现在回头看，当时的LLM其实蕴藏了很多能力，当时没有被充分利用

核心贡献

通过像模型展示推导的中间步骤，帮助模型进行 few-shot 学习，即可以大幅提升其在推理任务上的表现。充分的展示了模型的推理能力超出人们当时的认知，没有得到充分的利用（前提是模型规模大到足够“涌现”）

吸引scaling的重心中预训练逐渐转向后训练，以至后来thinking模型的诞生（作者后来去了openai，共同创立的O1项目）

人们最终意识到，LLM的输入会影响输出，逐渐的，输入（从prompt到context）变得越来越工程化

作者

Jason Wei：少数只有本科学历的研究员（毕业于达特茅斯）；知名网红，善于表达，值得关注（blog和公开视频都不错）

Denny Zhou: Gemini reasoning的负责人，在斯坦福 CS25 有个分享很值得看

LoRA: 那个我们每天都在用的东西（2021.06）

LoRA: Low-Rank Adaptation of Large Language Models

历史背景

总体上，人们一边忙着把模型搞大，同时也在积极解决模型变大带来的各种问题。很大的模型，SFT时既不好训，存储副本也很占地方（想想如果LoRA和Diffusion原版一样大）

如果给模型加入Adapter Layers，则会引入延迟；直接优化input layer难度很高

LoRA的预设模型是Transformer，但后来在Diffusion上大放异彩

作者

Edward Hu：Yoshua Bengio的学生，先后在微软研究院和OpenAI工作

作者有YouTube账号，对LoRA的讲解非常好，建议观看：
www.youtube.com/watch?v=DhRoTONcyZE

核心贡献

LoRA 以其简洁性、高效性（训练和推理）、以及与全量微调相当的性能，迅速成为高效微调领域最主流、最广泛使用的方法之一

冻结模型的原始权重（ W_0 ），在特定层旁边，注入一对维度更低的“秩分解矩阵”A 和 B。模型的输出更新为 $h = W_0x + BAx$ 。训练时 A 和 B 被更新，在推理时，可以预先计算出 $W' = W_0 + BA$ ，然后用 W' 替换原来的 W_0 。这样，部署时模型的结构和原始模型完全一样，不会引入任何额外的推理延迟。（有点像ResNet，只训练残差部分）

ReAct: Agent从理论到落地（2022.10）

ReAct: Synergizing Reasoning and Acting in Language Models

历史背景

Russell & Norvig在1995年提出了经典的Agent定义：Agent是任何能够通过传感器感知环境并通过执行器对环境采取行动的实体。LLM诞生后开始成为驱动Agent的核心，但此前其推理能力和行动能力主要作为独立主题进行研究

CoT证明了通过引导LLM进行逐步推理，可以显著提升其在复杂推理任务上的表现，但因为和现实世界没有交互，可能会产生事实幻觉；并且与现实世界脱节，无法影响原子世界

实际上，在ChatGPT出现之前，COT/ReAct等影响我们现在context engineering/agent/thinking等关键概念的基础工作，就已经出现了（但在当初看来可能没有那么明显，两位作者的引用量暴涨主要还是从24年开始）

核心贡献

作者注意到，人类智能的一个独特特征是能够无缝地将任务导向的行动与言语推理结合起来，这种“行动”与“推理”之间的紧密协同作用使人类能够快速学习新任务，并在面对前所未见的情况或信息不确定性时进行稳健的决策或推理


将上述理解代入研究中，让现有范式进一步突破：使用LLMs以交错方式生成推理轨迹和任务特定行动（tool use），边思考边行动，形成一个动态的感知-决策-执行循环。在很多任务上都取得了显著的性能提升，同时还提高了模型的可解释性和可信度（想想Claude4里的交错思考）

奠定了当下Agent的基础结构，LangChain/LangGraph里对其有专门的抽象

作者

姚顺雨，00后，毕业于清华姚班。姚班联席会主席/清华大学学生说唱社联合创始人/普林斯顿计算机博士/OpenAI研究员

SWE-bench的作者




The Bitter Lesson: 过去70年的教训 (2018.08)

The Bitter Lesson

The biggest lesson that can be read from 70 years of AI research is that general methods that leverage computation are ultimately the most effective, and by a large margin. The ultimate reason for this is Moore's law, or rather its generalization of continued exponentially falling cost per unit of computation. Most AI research has been conducted as if the computation available to the agent were constant (in which case leveraging human knowledge would be one of the only ways to improve performance) but, over a slightly longer time than a typical research project, massively more computation inevitably becomes available. Seeking an improvement that makes a difference in the shorter term, researchers seek to leverage their human knowledge of the domain, but the only thing that matters in the long run is the leveraging of computation. These two need not run counter to each other, but in practice they tend to. Time spent on one is time not spent on the other. There are psychological commitments to investment in one approach or the other. And the human-knowledge approach tends to complicate methods in ways that make them less suited to taking advantage of general methods leveraging computation. There were many examples of AI researchers' belated learning of this bitter lesson, and it is instructive to review some of the most prominent.

从 70 年人工智能研究中可以汲取的最大教训是：利用计算的通用方法最终最为有效，且优势显著。其根本原因在于摩尔定律，或者说更广义的计算单位成本持续指数级下降的规律。大多数人工智能研究仿佛是在假设智能体可用的计算资源恒定不变（在此情况下，利用人类知识成为提升性能的少数途径之一），然而，只需比典型研究项目稍长的时间跨度，海量计算资源必将变得触手可及。研究者寻求短期内见效的改进，往往倾向于运用其对该领域的人类知识，但长远来看唯一重要的是对计算资源的利用。这两者本不必相互对立，但实践中往往如此。投入一方的时间意味着另一方时间的缺失。心理上对某种方法的投入承诺也会形成路径依赖。而依赖人类知识的方法常会使技术复杂化，从而削弱其与通用计算方法的兼容性。人工智能研究者们对此苦涩教训的滞后认知不乏其例，回顾其中若干典型案例颇具启发意义。



The Bitter Lesson: 过去70年的教训（2018.08）

The Bitter Lesson

In computer chess, the methods that defeated the world champion, Kasparov, in 1997, were based on massive, deep search. At the time, this was looked upon with dismay by the majority of computer-chess researchers who had pursued methods that leveraged human understanding of the special structure of chess. When a simpler, search-based approach with special hardware and software proved vastly more effective, these human-knowledge-based chess researchers were not good losers. They said that "brute force" search may have won this time, but it was not a general strategy, and anyway it was not how people played chess. These researchers wanted methods based on human input to win and were disappointed when they did not.

A similar pattern of research progress was seen in computer Go, only delayed by a further 20 years. Enormous initial efforts went into avoiding search by taking advantage of human knowledge, or of the special features of the game, but all those efforts proved irrelevant, or worse, once search was applied effectively at scale. Also important was the use of learning by self play to learn a value function (as it was in many other games and even in chess, although learning did not play a big role in the 1997 program that first beat a world champion). Learning by self play, and learning in general, is like search in that it enables massive computation to be brought to bear. Search and learning are the two most important classes of techniques for utilizing massive amounts of computation in AI research. In computer Go, as in computer chess, researchers' initial effort was directed towards utilizing human understanding (so that less search was needed) and only much later was much greater success had by embracing search and learning.

在计算机国际象棋领域，1997 年击败世界冠军卡斯帕罗夫的方法依赖于大规模深度搜索。当时，这令多数致力于利用人类对棋局特殊结构理解的计算机象棋研究者感到沮丧。当配备专用软硬件的简单搜索方法展现出远超预期的效果时，这些基于人类知识的象棋研究者表现得缺乏风度。他们辩称“暴力”搜索或许这次侥幸获胜，但并非通用策略，且与人类下棋方式背道而驰。这些研究者曾期待基于人类智慧的方法胜出，因而对结果深感失望。

计算机围棋研究也呈现出相似的发展轨迹，只是延后了二十年。早期大量尝试都试图通过人类知识或游戏特性规避搜索，但当大规模搜索被有效应用时，这些努力不仅被证明徒劳无功，甚至适得其反。同样关键的是通过自我对弈学习价值函数（这一方法在其他游戏乃至国际象棋中亦有应用，尽管在 1997 年首次击败世界冠军的程序中学习机制并未发挥主要作用）。自我对弈学习与广义学习机制如同搜索，都能调动海量计算资源。搜索与学习正是人工智能研究中利用大规模计算的两大核心技术。与计算机象棋如出一辙，围棋研究者初期致力于运用人类理解（以减少搜索需求），直到后期才通过拥抱搜索与学习取得重大突破。

In speech recognition, there was an early competition, sponsored by DARPA, in the 1970s. Entrants included a host of special methods that took advantage of human knowledge---knowledge of words, of phonemes, of the human vocal tract, etc. On the other side were newer methods that were more statistical in nature and did much more computation, based on hidden Markov models (HMMs). Again, the statistical methods won out over the human-knowledge-based methods. This led to a major change in all of natural language processing, gradually over decades, where statistics and computation came to dominate the field. The recent rise of deep learning in speech recognition is the most recent step in this consistent direction. Deep learning methods rely even less on human knowledge, and use even more computation, together with learning on huge training sets, to produce dramatically better speech recognition systems. As in the games, researchers always tried to make systems that worked the way the researchers thought their own minds worked---they tried to put that knowledge in their systems---but it proved ultimately counterproductive, and a colossal waste of researcher's time, when, through Moore's law, massive computation became available and a means was found to put it to good use.

In computer vision, there has been a similar pattern. Early methods conceived of vision as searching for edges, or generalized cylinders, or in terms of SIFT features. But today all this is discarded. Modern deep-learning neural networks use only the notions of convolution and certain kinds of invariances, and perform much better.

在语音识别领域，20 世纪 70 年代曾有一场由 DARPA 赞助的早期竞赛。参赛者中既有依赖人类知识（如词汇、音素、人类声道等）的一系列特殊方法，也有基于隐马尔可夫模型（HMMs）、计算量更大且更具统计性质的新方法。统计方法再次战胜了基于人类知识的方法。这一结果促使整个自然语言处理领域在随后几十年间逐步发生重大转变，统计学与计算技术开始主导该领域。近期深度学习在语音识别中的崛起，正是这一持续趋势的最新体现。深度学习方法对人类知识的依赖更少，通过结合海量训练集的学习与更庞大的计算量，实现了语音识别系统的显著提升。如同在游戏领域，研究人员曾试图构建符合其思维模式的系统——将这类知识编码进系统——但随着摩尔定律使大规模计算成为可能，并找到有效利用途径后，这种尝试最终被证明适得其反，且极大浪费了研究者的时间。

计算机视觉领域也呈现类似的发展轨迹。早期方法将视觉视为边缘检测、广义柱面或 SIFT 特征的搜索过程。但如今这些方法已被完全摒弃。现代深度学习神经网络仅运用卷积概念与特定不变性原则，却实现了更卓越的性能。

The Bitter Lesson: 过去70年的教训（2018.08）

The Bitter Lesson

This is a big lesson. As a field, we still have not thoroughly learned it, as we are continuing to make the same kind of mistakes. To see this, and to effectively resist it, we have to understand the appeal of these mistakes. We have to learn the bitter lesson that building in how we think we think does not work in the long run. The bitter lesson is based on the historical observations that

1) AI researchers have often tried to build knowledge into their agents, 2) this always helps in the short term, and is personally satisfying to the researcher, but 3) in the long run it plateaus and even inhibits further progress, and 4) breakthrough progress eventually arrives by an opposing approach based on scaling computation by search and learning. The eventual success is tinged with bitterness, and often incompletely digested, because it is success over a favored, human-centric approach.

One thing that should be learned from the bitter lesson is the great power of general purpose methods, of methods that continue to scale with increased computation even as the available computation becomes very great. The two methods that seem to scale arbitrarily in this way are search and learning.

这是一个深刻的教训。作为一个领域，我们仍未彻底领悟它，因为我们仍在重复同类错误。要看清这一点并有效抵制，我们必须理解这些错误的吸引力所在。我们必须汲取这个苦涩的教训：**按照我们自以为的思维方式构建系统，长远来看终将失败。**这一教训基于历史观察：

1) AI 研究者常试图将知识编码入其智能体；2) 这在短期内总是有效，且令研究者个人满足；3) 但长期会陷入平台期甚至阻碍进展；4) 突破性进展最终来自相反路径——通过搜索和学习实现计算规模扩展。这种成功带着苦涩，常未被完全消化，因它战胜了备受青睐的、以人类为中心的研究范式。

从这一苦涩教训中我们应认识到通用方法的强大力量——那些能随算力增长持续扩展的方法，即便可用计算资源变得极其庞大时亦然。目前看来能以这种方式无限扩展的两种方法正是搜索与学习。


The Bitter Lesson: 过去70年的教训（2018.08）

The Bitter Lesson

The second general point to be learned from the bitter lesson is that the actual contents of minds are tremendously, irredeemably complex; we should stop trying to find simple ways to think about the contents of minds, such as simple ways to think about space, objects, multiple agents, or symmetries. All these are part of the arbitrary, intrinsically-complex, outside world. They are not what should be built in, as their complexity is endless; instead we should build in only the meta-methods that can find and capture this arbitrary complexity. Essential to these methods is that they can find good approximations, but the search for them should be by our methods, not by us. We want AI agents that can discover like we can, not which contain what we have discovered. Building in our discoveries only makes it harder to see how the discovering process can be done.

从这一惨痛教训中获得的第二个普遍要点是，心智的实际内容极其复杂且无法简化；我们应停止寻找理解心智内容的简单途径，诸如思考空间、物体、多智能体或对称性的简单方法。这些都是外在世界中任意、本质复杂的一部分，不应被内置，因为它们的复杂性无穷无尽；相反，我们应仅内置那些能够发现并捕捉这种任意复杂性的元方法。这些方法的核心在于它们能找到良好的近似解，但寻找这些近似解的过程应由我们的方法完成，而非由我们亲力亲为。我们需要的是能像我们一样有能力发现的人工智能体，而非装载了我们已有发现的智能体。内置我们的发现只会让理解发现过程如何实现变得更加困难。

Infra与数据的变迁



ZeRO: 大规模的GPU并行计算（2019.10）

ZeRO: Memory Optimizations Toward Training Trillion Parameter Models

历史背景

模型在快速扩大，参数从亿到千亿（GPT从1.2-15-1750亿），但GPU的显存只从16GB到80GB，一张卡装不下一个模型了

现有模型并行、数据并行、流水线并行的方法，均存在一些问题

核心贡献

在数据并行的框架内对训练过程中的模型状态（优化器状态、梯度、参数）进行切分和动态管理

通过消除并行训练中冗余模型状态的内存冗余，使得可训练的模型大小与GPU集群的总显存成正比，理论上可以无限扩展。

成为DeepSpeed的核心工作并开源

Scaling Law & Chinchilla: 上帝的指挥棒 (2020.01 2022.03)

Scaling Laws for Neural Language Models

历史背景

虽然人们相信模型越大越好，但数据和计算资源是有边界的。这三者的资源该如何分配，以及计算资源固定时，怎么调整模型规模和数据量？OpenAI和DeepMind团队先后做了实证研究，形成了今天指导模型训练的Scaling Law



核心贡献

发现语言模型的训练Loss遵循幂律关系（对数线性）：当其他两个因素不成瓶颈时，经验性能与每个单独因素都存在幂律关系。此时，我们可以用小模型实验出来的数据点，预测模型扩大时的性能。这样，我们可以在小模型上做大量的实验，并推测放大后的实际性能是否满足要求。

此时，我们可以用小模型实验出来的数据点，预测模型扩大时的性能。这样，我们可以在小模型上做大量的实验，并推测放大后的实际性能是否满足要求。

OpenAI建议在给定计算预算下，应该训练尽可能大的模型，即使这意味着提前停止训练；DeepMind做了大量实验后认为，OpenAI的策略导致很多模型训练不足（只扩展模型规模没有扩展数据）。对于计算最优训练，模型规模和训练token数量应该等比例扩展：每当模型规模翻倍时，训练token数量也应该翻倍

Chinchilla证明，用更多数据训练更小的模型比用较少数据训练更大的模型效果更好：可以拿到推理时小模型的收益



LAION-5B: 开源社区的英雄主义（2022.10）

LAION-5B: An open large-scale dataset for training next generation image-text models

历史背景

OpenAI 2021年初发布了CLIP 模型，证明了通过对比学习，可以在大规模（4亿）图像-文本对上预训练出强大的视觉-语言联合表示模型，具有惊人的零样本学习能力。这激发了更大规模图像-文本数据集的需求。

CLIP 虽然公开了权重，但其训练所用的 4 亿数据并未公开。Christoph Schuhmann等项目创始人认为，人工智能研究里，如果一直是闭源的，完全由少数几个工业巨头垄断并断决定整个研究领域的发展方向，这对我们未来的社会非常不利。

核心贡献

以开源协作的方式，LAION社区利用CLIP过滤Common Crawl数据，构造了 LAION-5B 数据集，包含58.5 亿个 CLIP（Contrastive Language-Image Pre-training）过滤后的图像-文本对。

LAION-5B 是继 ImageNet 之后，在多模态领域最具影响力的公开数据集之一，它直接或间接地催生了 AIGC领域的创新浪潮，Stable Diffusion即在这个数据集上训练构建

作者

Christoph Schuhmann是一名德国高中的物理和计算机科学教师！

The RefinedWeb: 互联网的数据也够用（2023.06）

A New High-Quality, Massive-Scale Web Corpus

历史背景

在对Scaling Law的研究中人们意识到，数据需要和模型规模同步scale，才能充分利用算力；甚至可以用更多的数据和算力，对更小的模型进行过度训练

LLM的训练通常依赖于经过滤的网页数据与精选的“高质量”语料库（如书籍、技术论文、社交媒体对话等）的混合。人们这种精心的语料策划对于训练出具备强大零样本泛化能力的模型是必不可少的。但高质量语料库难以获取，构建成本高，事实上被大公司垄断

核心贡献

证明了仅仅使用清洗Common Crawl得到的大规模、高质量的网页数据集（RefinedWeb）进行训练，就可以达到甚至超越“人工精选的混合语料库”的效果。找到了解决“数据墙”问题的新范式

通过先进的数据处理技术，完全可以从公开的、看似杂乱的网页数据中“提炼”出比传统精选语料库更高质量的训练数据，从而以更低成本、更大规模地训练出顶尖的语言模型。极大地推动了“数据工程”在大模型训练中的核心地位。

MegaScale: 万卡GPU集群的训练（2024.02）

MegaScale: Scaling Large Language Model Training to More Than 10,000 GPUs

历史背景

GPT3这样的1750亿参数的模型，需要在大规模的GPU集群上进行单个job的训练，这在infra层面带来了极大的挑战：训练效率/训练稳定性


ChatGPT之后，模型厂商之间展开了军备竞赛，并且开始高度保密，很少发表大规模集群训练的论文

核心贡献

首个公开发表的生产环境中万卡训练论文，采用了Algorithm-System（算法-infra） Co-design的方式，实现高训练效率

根据深度可观测性的原则，建立了一套系统，对训练进行监控和可视化，诊断infra的问题和归因，并自动化定位故障和恢复。

语言模型的发展



Word2Vec: 用机器学习将单词向量化（2013.01）

Efficient Estimation of Word Representations in Vector Space

历史背景

过去的人们认为，单词是语言的最小单元，搞清楚单词的语义，对理解句子的含义十分重要，所以试图寻找单词在向量空间中更好的语义表示。但过去的方式都把单词视为孤立的原子，他们的表示之间并无语义联系，这更像是一种词汇表中的索引

有一些神经网络的方法试图捕获语义的连续表示，但计算复杂度大。即便如此，人们也发现，单词向量可以显著改进和简化许多自然语言处理应用程序，所以具备很高的研究价值。

核心贡献

开创新的范式：首次找到了一种对单词连续且包含语义的向量表示（king - man + woman $\approx$ queen），后被广泛的用于从搜索到推荐等各种NLP系统

与之前的神经网络模型相比，Word2Vec大大降低了计算成本，使得在超大规模语料库上训练词向量成为可能，下游任务可以使用这样的词向量来大幅简化结构和提升效果

作者

Tomas Mikolov, Jeffrey Dean

Google Translate: 神经网络的大规模线上部署（2016.09）

Google's Neural Machine Translation System: Bridging the Gap between Human and Machine Translation

历史背景

过去机器翻译的主流技术是基于统计的（SMT），特别是基于短语的机器翻译（PBMT）；但翻译实际上是一个 seq2seq 的任务，基于神经网络的方法在学术界的努力下，在这个领域已经展现了极大的潜力

但在生产环境的实践中，基于神经网络的NMT系统在准确性上一度不如基于短语的翻译系统：训练与推理速度较慢、处理罕见词汇效果不佳，以及有时无法翻译源句中的所有词汇

核心贡献

引领了工业场景中的翻译范式转移：构建了一个生产级 NMT 系统，解决了上述问题，相较于之前Google基于短语的生产翻译系统实现了显著的改进

在工程实践中采用了大量学术界的最新成果：ResNet，Encoder-Decoder结构对序列建模，注意力机制，低精度计算/数据并行/模型并行；是工程上的集大成者

作者

吴永辉：Google Fellow，Gemini Post train负责人，字节seed负责人

Quoc V. Le/Oriol Vinyals/Jeffrey Dean

GPT-1，它来了（2018.06）

Improving Language Understanding by Generative Pre-Training

历史背景

虽然深度学习模型在多个NLP任务上取得了进展，但这些模型通常依赖大量专门标注的数据和单独的训练，既耗时间又耗资源，同时对标注的依赖限制了其应用范围（有些领域缺乏标注）

CV领域中一直有迁移学习的范式：通过预训练学习通用的知识（规律），然后通过对特定任务标注数据的微调，来做适应。NLP中虽然也有，但都是Word2Vec这样以单词embedding为核心的工作，并没有方法学习语言本身的规律

核心贡献

提出了学习语言规律并解决下游任务的新范式：无监督预训练+监督微调，并首次使用通用数据的预训练学习到了语言的内在规律（后面发现可以学到世界知识），可以在后续的微调中更好泛化到下游任务

建立了以Transformer的Decoder为模型结构，next token prediction为训练目标的语言模型训练范式，后来成为LLM的主导范式

使用BooksCorpus（~5GB）作为训练语料，参数量0.1B

作者

Alec Radford、Karthik Narasimhan（姚顺雨导师）、Tim Salimans和Ilya Sutskever

2015年的时候，Ilya在找无监督学习的数学证明，并独立发现了它。说明15年就有这个想法了，18年借助Transformer将其实现

BERT: 曾经的王（2018.10）

历史背景

事物的发展并不总是一帆风顺的。GPT刚出来混，就被BERT捶了。

BERT继承了GPT预训练-微调的范式，并且因为是双向表示，性能更强大

核心贡献

引入了深度双向预训练的范式，使得模型可以同时考虑一个词左右两边的上下文信息。几乎横扫了当时所有主流的NLP基准测试。

提出Next Sentence Prediction (NSP) 预训练任务

BERT-Base：0.11B；BERT-Large：0.34B

BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

作者

BERT作者对GPT的评价：在OpenAI GPT中，作者使用了一个从左到右的架构，在这种架构中，每个标记只能在Transformer的自注意力层中关注先前的标记。这种限制对于句子级任务来说是次优的，并且在将基于微调的方法应用于诸如问答之类的标记级任务时可能非常有害，因为在这种任务中，从两个方向都融入上下文是至关重要的。

GPT-2: 是时候告别微调了（2019.02）

Language Models are Unsupervised Multitask Learners

历史背景

在被BERT捶的日子里，OpenAI坚持了他们的看法。预训练-微调的范式意味着，模型没有本质上学会世界知识，仍然是一种“狭窄专家”，这可能是过于单一的训练数据集导致的（GPT-1 的BooksCorpus）

2. OpenAI相信，在一个足够大和具备多样性的数据集上进行token预测（无监督多任务学习），Transformer能学习到语言本身丰富的规律，对其建模（初步的世界模型）

作者

Alec Radford、Dario Amodei、Ilya Sutskever

致谢中感谢了noam

核心贡献

训练了一个1.5B的 Transformer 模型，通过爬取 Reddit构建了具备多样性的WebText (~40GB)数据集，将数据和模型规模均扩展了10倍

GPT-2无需进行任何任务相关的梯度更新或架构修改（不再需要微调），即可直接泛化到多种不同的 NLP 任务上，实现了前所未有的零样本学习

GPT-3: ChatGPT来临前夜（2020.05）

Language Models are Few-Shot Learners

历史背景

OpenAI最初是一个纯粹的非营利组织，但在2019年3月（GPT-2发布1个月后），Sam Altman推动成立了一个新的、名为 OpenAI LP 的“有限盈利”公司，2019年7月，微软向OpenAI LP投资了10亿美元，并提供Azure的算力支持（此时，微软内部的ZeRO等infra工作也有了成果）

GPT-2的论文作者有6位，是一个典型的研究小组；GPT-3的论文作者多达31人，加入了数据工程/infra/评估等多个角色，OpenAI显著的增加了资源投入，把GPT-3视为一个大型的工程项目而非研究工作来开展

Jared Kaplan在GPT-3的工作中，已经应用scaling law来帮助预测和指导研究中的模型和数据缩放决策。

从这些迹象中我们可以看到，OpenAI在GPT-2的scaling工作中识别到了重要的信号，开始挑战组织和策略，进行了非常坚决的投入

核心贡献

人类并不需要大量的监督数据就能够学习语言任务，最多需要少量的示例。虽然GPT-2试图通过上下文学习来实现这一点，且体现出潜力，但相较微调效果还是比较差。OpenAI注意到，随着transformer模型参数量的提升，上下文学习能力可能会随着模型规模的扩大而呈现出同样显著的提升（scaling law）。

OpenAI组织了充分的工程资源，扩大模型参数，重新清洗数据（搞定了之前没法用的Common Crawl），解决大规模GPU的并行训练问题，最终训练了一个1750亿参数的GPT-3模型，验证了scaling law，得到了强大的上下文学习能力（训练使用了~570GB数据，但参数较GPT-2扩展了100倍，后来的观点看是训练不充分的）

新的LLM使用范式诞生：仅通过设计输入提示（Prompt），包含任务描述和少量范例，就能引导大型模型执行特定任务。这个方式至今任在指导我们的工作，只不过进化成了context engineering

作者

Alec Radford、Dario Amodei、Ilya Sutskever

InstructGPT: 给LLM以文明（2022.03）

Training language models to follow instructions with human feedback

历史背景

GPT-3带来了巨大的范式变革，也产生了新的问题：会生成不真实、有毒害或是无助于用户任务的输出；这种对用户指令遵循的问题，并没有随着scaling而改善

换言之，这些模型与用户意图不一致：GPT-3 在字面完成任务上很强，但无法理解“用户真正的意图”，既不会拒绝有害任务，也不会澄清模糊需求，还会生成自信却错误的内容。

核心贡献

提出了基于人类反馈的强化学习 (RLHF)：SFT+RM+PPO，通过这个过程，模型不仅学会了如何响应指令（SFT），还学会了根据人类的细微偏好来调整其行为（RM + RL），从而生成更符合期望的输出。

证明了 1.3B 的 InstructGPT 在遵循指令方面优于 175B 的 GPT-3，这启发了业界思考，除了单纯扩大模型规模外，优化训练方法和目标同样重要，甚至更有效

作者

Long Ouyang, John Schulman：PPO的作者

Jan Leike和 Paul Christiano：Alignment团队

Tulu 3: 后训练的开源（2024.11）

TULU 3: The Art and Science of Instruction Tuning at Scale

历史背景

语言模型的“后训练”（Post-Training）阶段，包括指令微调（Instruction Tuning）和基于人类反馈的强化学习（RLHF），是提升模型能力、使其行为与人类意图对齐的关键步骤。然而，长期以来，最先进的后训练技术细节往往被少数顶尖的闭源模型（如GPT系列）所垄断，其训练数据、方法和具体“配方”（recipes）缺乏透明度，这极大地阻碍了开放社区的研究进展。

为了弥合这一差距，艾伦人工智能研究所推出了Tulu 3，一个完全开放的、性能顶尖的后训练模型家族。Tulu 3不仅提供了模型权重，更重要的是，它将整个后训练流程所需的数据、代码、训练配方和评估体系完全公开。Tulu 3基于Llama 3.1系列基础模型进行后训练，其性能在多个基准测试中超越了包括Llama 3.1-Instruct、Qwen 2.5、Mistral在内的顶尖开源模型，甚至在某些方面能够媲美GPT-4o-mini和Claude 3.5-Haiku等强大的闭源模型。

核心贡献

三阶段的后训练流程：

第一阶段：监督微调 (SFT)：使用精心筛选的“指令-回答”对数据对基础模型进行微调。这一步的目标是让模型学会理解和回应各种类型的指令，为后续的对齐打下基础。Tulu 3在数据配比上做了大量实验，以平衡模型的各项能力。


第二阶段：直接偏好优化 (DPO)：在SFT模型的基础上，使用偏好数据集进行训练。这些数据通常包含一个问题和两个不同的回答，并标注哪一个更好。DPO算法能直接根据这些偏好来调整模型，使其生成更符合人类喜好的内容。Tulu 3团队也通过模型自身生成回答再由更强模型进行标注的方式，高效地扩大了偏好数据集的规模。

第三阶段：基于可验证奖励的强化学习 (RLVR)：针对数学和编程这类有明确正确答案的任务，DPO的效果有限。RLVR方法让模型生成多个答案，然后用一个外部的验证器（例如一个代码解释器或数学求解器）来判断答案是否正确。正确的答案会获得高奖励，错误的则获得低奖励。通过强化学习算法，模型会逐渐学会生成能通过验证的正确答案。这一步极大地提升了模型在逻辑推理任务上的可靠性。

作者

一作Nathan Lambert是Allen Institute for AI的研究科学家和后训练团队负责人，也是著名AI新闻通讯Interconnects.ai的作者

多模态模型的发展



DeepVideo: 深度学习进入视频领域，Andrej 初出茅庐（2014.06）

Large-scale Video Classification with Convolutional Neural Networks

历史背景

在AlexNet之前，视频领域也被手工特征的范式所主导。自然就会有人想，视频和图像相差没那么大，是否也可以用深度学习的范式做？如果不行，缺哪些要素呢？

从实际的角度看，缺乏一个类似ImageNet的大规模数据集；从建模的角度看，运动信息的建模是一个挑战；从计算的角度看，视频是多帧图像，需要的计算量大很多，训练神经网络是有挑战的。

核心贡献

构建了Sports-1M数据集，这是当时最大的视频分类数据集，包含100万个YouTube体育视频，分为487个体育类别

范式创新：借助在ImageNet上预训练好的CNN模型作为迁移学习的基础，用深度学习的方式解决了视频分类问题

探讨了Early Fusion、Late Fusion 等不同的融合方式，最后选了Slow Fusion（慢融合）。

留了一个bug：和单帧模型相比，改进的幅度不大，从 59.3% 到 60.9%

作者

Andrej Karpathy：当时还是斯坦福大学的博士生（导师是李飞飞），后来成为人工智能领域的杰出人物，曾任特斯拉AI总监，也是OpenAI的创始成员之一，对计算机视觉、自然语言处理和深度学习教育做出了重要贡献。

李飞飞：时任斯坦福大学教授，是人工智能和计算机视觉领域的领军人物，ImageNet项目的主要推动者，极大促进了深度学习的发展。她后来还担任过谷歌云首席科学家。

双流网络: Karén和学术重镇牛津登场（2014.06）

Two-Stream Convolutional Networks for Action Recognition in Videos

历史背景

Andrej Karpathy虽然解决了用深度学习做视频的挑战，但其效果仍然比不上最好的手工特征模型。同时，其时间流的学习效果并不好，多帧模型并没有比单帧模型好的很明显。

作者

Karén Simonyan后来成为DeepMind的主要研究科学家，在计算机视觉和深度学习领域做出了重大贡献，包括著名的VGG网络。后来成为Inflection co-founders，后被并购至Microsoft AI

2017年，Karén参与了AlphaGo Zero的工作，是同等贡献一作

核心贡献

新的范式性能追上旧范式：提出了一个融合空间和时间网络的双流卷积网络架构，性能与最先进的手工特征模型相当

双流架构和其融合方式成为后来大多数视频理解方法的基础框架，影响了后续几乎所有的视频分析深度学习研究

图像生成的序章: GAN来了 (2014.06)

Generative Adversarial Nets

历史背景

当时的人们倾向于认为，生成是一个比理解更复杂的任务。从规律的角度上来讲，我们需要先理解一个规律，才可能用这个规律去生成一个事物。

判别模型是封闭和收敛的任务，生成是开放和发散的任务；判别确实更好做一些

核心贡献

提出全新范式：将生成类的任务建模成了一个生成器与判别器做二人零和博弈的系统，用当时比较成熟也相对好做的判别模型（本质上是loss）来简化生成模型的训练

这是一个极具开创性的研究思路：不再追求训练一个神经网络模型，而是训练两个。用一个已经解决的问题来帮助解决另一个问题。

作者

Ian J. Goodfellow: 论文的第一作者，通常被认为是GANs的主要发明者。此后，他在深度学习领域，尤其是在GANs的研究、发展和推广方面，扮演了核心角色，著有经典的《Deep Learning》教科书（俗称花书，与Yoshua Bengio和Aaron Courville合著），并在Google Brain和Apple等顶级研究机构领导相关研究。他是对抗性样本和生成模型领域的权威人物。

Yoshua Bengio: 深度学习领域的奠基人之一，蒙特利尔学习算法研究所（MILA）的负责人，因其在深度学习领域的杰出贡献获得了2018年的图灵奖。作为Goodfellow的博士导师之一，他对GANs的早期发展提供了指导和支持，并在后续持续推动深度学习基础理论和应用的研究。

Aaron Courville: 同样是深度学习领域的重要研究者，也是《Deep Learning》教科书的作者之一，蒙特利尔大学的教授。他在深度学习模型，特别是生成模型和概率模型方面有深入研究，对GANs的理论完善和后续发展亦有贡献。

Diffusion: 在GAN的阴影下，悄然成长（2015.03）

Deep Unsupervised Learning using Nonequilibrium Thermodynamics

历史背景

本文解决了机器学习中的一个核心问题：如何构建既具有高度灵活性又保持计算可行性的概率分布模型。传统生成模型要么表达能力有限，要么在学习、采样和推断过程中计算复杂度过高。

在2015年，深度生成模型领域主要由变分自编码器（VAEs）和生成对抗网络（GANs）主导。VAEs通常能稳定训练，但生成的样本比较模糊；GANs能生成更锐利的样本，但训练不稳定，容易出现模式崩溃（Mode Collapse）等问题。研究者们一直在寻找新的、更稳定、能生成高质量样本且理论基础更扎实的生成模型框架。

核心贡献

从物理的扩散过程中汲取灵感，开创了生成模型的全新范式（具有高度灵活性又保持计算可行性）：首先，通过迭代的前向扩散过程，系统地逐渐破坏数据分布中的结构，最终将其转化为简单的噪声分布；然后，学习一个逆向扩散过程，恢复数据中的结构，从而得到一个既灵活又易于处理的生成模型

作者

引用自作者的blog：

Jascha最为(不)知名的工作是**发明扩散模型**。他最近的工作集中在过参数化神经网络理论、学习优化器的元训练以及理解大语言模型的能力上。他最近加入了Anthropic，是研究团队的一员。他曾在Google brain和deepmind担任主任科学家，在斯坦福大学苏里亚·甘古利的实验室做访问学者，还在教育非营利组织可汗学院担任学术驻场人员。他于2012年在加州大学伯克利分校的红木理论神经科学中心获得博士学位。在攻读博士学位之前，他从事向火星发射探测器的工作。

Abstract 摘要

A central problem in machine learning involves modeling complex data-sets using highly flexible families of probability distributions in which learning, sampling, inference, and evaluation are still analytically or computationally tractable. Here, we develop an approach that simultaneously achieves both flexibility and tractability. The essential idea, inspired by non-equilibrium statistical physics, is to systematically and slowly destroy structure in a data distribution through an iterative forward diffusion process. We then learn a reverse diffusion process that restores structure in data, yielding a highly flexible and tractable generative model of the data. This approach allows us to rapidly learn, sample from, and evaluate probabilities in deep generative models with thousands of layers or time steps, as well as to compute conditional and posterior probabilities under the learned model. We additionally release an open source reference implementation of the algorithm.

机器学习中一个核心问题在于使用高度灵活的概率分布家族来建模复杂的数据集，同时保持学习、采样、推理和评估的分析或计算可行性。在这里，我们开发了一种方法，同时实现了灵活性和可计算性。基本的想法，受到非平衡统计物理学的启发，是通过迭代向前扩散过程系统地 and 缓慢地破坏数据分布中的结构。然后，我们学习一个反向扩散过程，以在数据中恢复结构，从而生成一个高度灵活且可计算的数据生成模型。这种方法使我们能够快速学习、从模型中采样以及评估具有数千层或时间步的深度生成模型中的概率，以及在学习的模型下计算条件概率和后验概率。此外，我们还发布了一个开源的算法参考实现。

DDPM: Diffusion重回图像舞台的中央（2020.06）

Denoising Diffusion Probabilistic Models

历史背景

这篇论文诞生时，生成模型领域主要由GANs（能生成非常逼真的图像，但训练过程不稳定，容易出现模式坍塌）、变分自编码器VAEs（训练稳定，但通常生成的样本较为模糊）和自回归模型（Autoregressive Models，生成过程是序列化的，速度非常慢，尤其对于高分辨率图像）主导。

Diffusion在2015年已经被提出，但效果欠佳，难以训练且计算成本高昂，未能引起广泛关注。

作者

Jonathan Ho: 当时在Google Brain团队（后来并入Google Research/Google DeepMind）。他是这篇论文和后续许多关键扩散模型研究（如Imagen）的核心推动者，后联合创立Ideogram

Ajay Jain: 同在Google Brain团队。他在生成模型领域持续进行研究，为Google的AI研究贡献力量。

Pieter Abbeel: 加州大学伯克利分校的著名教授，同时也是Google Brain的访问研究员以及AI初创公司Covariant的联合创始人。Abbeel教授是机器学习、机器人学和强化学习领域的顶尖专家，他的指导和参与为这项工作带来了深厚的学术背景和影响力，他的实验室也持续产出重要的AI研究成果。

核心贡献

将Diffusion从一个边缘的范式带回到主流：训练稳定，效果不输GAN

简化了模型设计和训练目标，他们不再直接学习反向过程的均值和方差（去噪后的图像均值），而是预测添加到图像中的噪声（去掉噪声就是下一步的图像），使得学习过程更简单也更稳定。这个做法很像ResNet。

引入了U-Net作为骨干网络，用于预测扩散过程中的噪声

ViT: 当图像遇到Transformer（2020.10）

An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale

历史背景

虽然Transformer 席卷NLP领域，但图像识别仍然由CNN主导。有人尝试使用注意力和CNN结合，但由于使用了专门的注意力模式，未能在GPU上有效扩展（又一个没有抽中硬件彩票的）。在大规模图像识别中，经典的ResNet-like架构仍然是最先进的

图像处理的背景下应用Transformer时，人们尝试了各种注意力架构，许多这些专门的注意力架构在计算机视觉任务上展示了有希望的结果，但需要复杂的工程设计才能在GPU上高效实现

Transformer 是一个处理序列（Sequence）并建模其内部及序列之间关系的架构，但图像是二维的，天然不存在token（而且还是有限的token）这件事。

作者

论文的顾问Jakob Uszkoreit 是原 Transformer 论文 ("Attention Is All You Need") 的作者之一

核心贡献

进行了巨大的范式创新：如果不能让模型适应数据，那就让数据适应模型（An Image is Worth 16x16 Words）。将图片拆解为 16x16 像素的Patch，对其进行和token一样的处理

完完整整的享受了Transformer的算法/infra生态优势，可以进行非常大的scaling

新的范式性能突破，推动CV领域的范式从CNN迁移到Transformer：当在大量数据上进行预训练并转移到多个中等或小型图像识别基准（ImageNet、CIFAR-100、VTAB等）时，Vision Transformer（ViT）相比最先进的卷积网络取得了出色的结果，同时需要较少的计算资源进行训练。

CLIP: 文生图的奠基石（2021.03）

Learning Transferable Visual Models From Natural Language Supervision

历史背景

1. 在文本领域（NLP），用预训练的方式对大规模的网络无监督数据进行处理，取得了良好的成果（BERT, GPT）。在这种大型的多任务学习中，模型获取到丰富的语言/世界知识，并展现出强大的迁移能力。
2. 当时的CV模型依赖于人工标注的数据集（如ImageNet），创建成本高昂、耗时，且覆盖的视觉概念有限（例如ImageNet只有1000个类别），不具备zero-shot能力（从这个角度看，不是通用智能）

作者

Alec Radford（GPT系列的一作）、Jong Wook Kim、Chris Hallacy、Aditya Ramesh、Gabriel Goh、Sandhini Agarwal、Girish Sastry、Amanda Askell、Pamela Mishkin、Jack Clark、Gretchen Krueger和Ilya Sutskever

核心贡献

首次成功地将对比学习的方法用于视觉和语言两个模态，并证明了可以利用互联网上的自然语言作为监督信号，来学习一个强大、通用的多模态表示空间。其中图像部分用了ViT的方式（也试了ResNet）

激发了文生图的新范式：因为其将图片和文本进行了建模，后来的Diffusion生图模型利用了这种能力，使得我们可以用文字来引导图片的生成

CLIP模型可以直接用于零样本图像分类，性能上优于最好的公开可用的 ImageNet 模型，同时在计算效率上也更高；CLIP通过对比学习有了很好的泛化性：包括 OCR、地理定位、动作识别等

Stable Diffusion，它来了（2021.12）

High-Resolution Image Synthesis with Latent Diffusion Models

历史背景

当时的扩散模型都工作在像素空间。不管是训练还是推理，都非常耗费计算资源（生成图片也很缓慢），使其只能由大公司开发和使用。同时，这种范式也让高分辨率图像由于急剧的增加资源消耗而难以实用化。

OpenAI 的 GLIDE探索了将文本信息（通过一个类似 CLIP 的文本编码器处理）作为条件（conditioning）输入到扩散模型的 U-Net 噪声预测网络中，从而让模型直接生成符合描述的图像，但整体的控制能力还是偏弱

核心贡献

大幅提高了扩散模型的训练和推理效率：在一个低维（从而高效）的表示空间（潜空间）中训练扩散模型，再将学习到的表示解码回像素空间

在架构中引入交叉注意力层，使模型可以响应用户条件输入（如文本或边界框），从而具备了控制能力：使用一个预训练好的 CLIP 模型的文本编码器（Text Encoder）来处理输入的文本提示（Prompt），并将编码后的文本特征作为条件，输入到在潜空间中工作的 U-Net 网络里，引导图像的生成

作者

Robin Rombach、Andreas Blattmann、Dominik Lorenz、Patrick Esser和Björn Ommer，均来自德国海德堡大学和CompVis实验室。Robin Rombach和Patrick Esser后来成为Stability AI的核心研究者，引领了Stable Diffusion系列模型的开发

DiT: 人们期待一个融合的未来（2022.12）

Scalable Diffusion Models with Transformers

历史背景

扩散模型在图像生成领域迅速崛起，DDPM、Stable Diffusion等模型展示了惊人的生成能力，但主要依赖U-Net这种基于CNN的架构。

相对于Transformer，U-Net的架构scaling的潜力有限，全局建模能力也相对较弱。如果能把预测噪声的骨干网络替换成Transformer，应该能把模型性能进一步提高

ViT的工作，展示了Transformer用于图像领域的潜力，也有了基础的解决方案

作者

主要作者是William Peebles和谢赛宁。

William Peebles 在完成这项工作后，前往 OpenAI，并成为后来引起轰动的文生视频模型 Sora 的核心研发成员之一，进一步验证了 Transformer 架构在处理大规模视觉生成任务上的潜力；

谢赛宁时任纽约大学助理教授（后加入 Meta AI），在计算机视觉和深度学习领域是一位有影响力的研究者，其工作（如 ResNeXt, ViT 等）对模型架构设计产生了持续的影响。

核心贡献

通过用Transformer替换Stable Diffusion潜空间中的U-Net，大幅提高了模型的扩展性，并取得性能提升（论文标题：Scalable Diffusion Models with Transformers）

将架构统一到Transformer：能够持续受益于其他领域的最佳实践和训练配方，同时保留可扩展性、鲁棒性和效率等有利特性（抱住硬件彩票大腿）。统一的架构给跨领域研究带来新的可能性。

THANKS

美团光年之外产品负责人 | 谢青池

即刻/小红书 @skyxqc